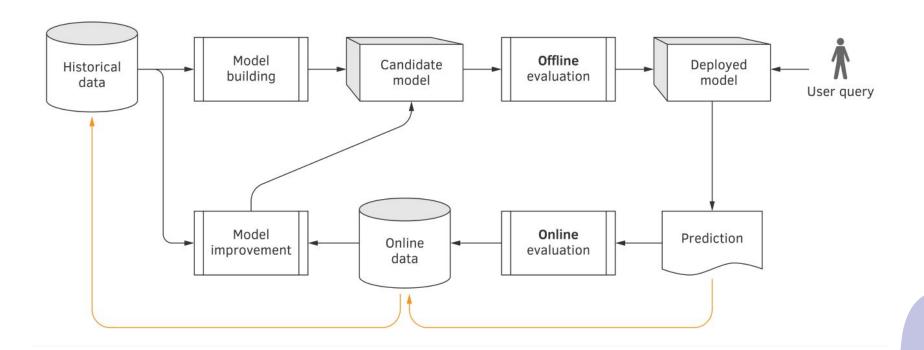
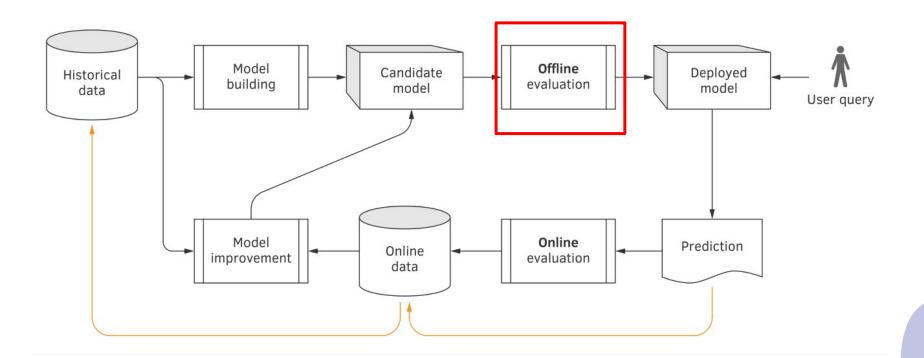
# Fondamenti MLOps: parte 3

#### Debugging dei modelli



#### Debugging dei modelli



#### Programma di oggi

Debugging e analisi dei modelli → Da pre-produzione a produzione

#### Tramite:

- 1. Utilizzo tecniche **eXplainable AI** (XAI)
- 2. Applicazione di concetti fondamentali di **analisi di incertezza** in ambito machine learning.

### Possibili problemi legati ai modelli

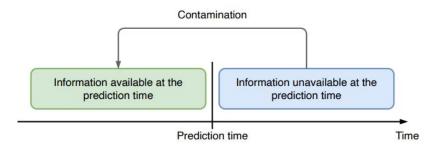
(che affronteremo oggi)

- 1) Data leakage
- 2) Robustezza modelli
- 3) Bias e fairness

#### Data leakage

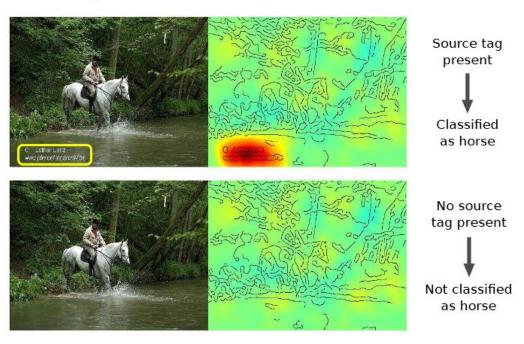
Il modello viene fornito in fase di allenamento di dati che non sono presenti in fase di inferenza. Motivi tipici:

- Una delle features 'nasconde' il target
- Una delle features viene dal 'futuro'



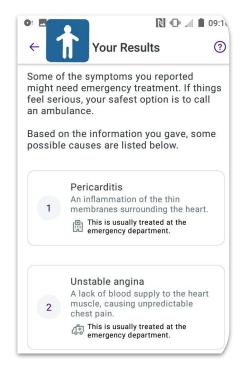
#### Data leakage

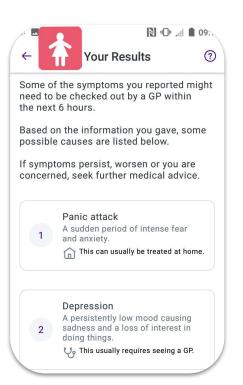
#### Horse-picture from Pascal VOC data set



Unmasking Clever Hans Predictors and Assessing What Machines Really Learn. Lapuschkin et al. Nature comm (2019)

Modelli imparano da dati → Dati possono contenere diversi tipi di bias che potrebbero non risultare accettabili in un modello in produzione.





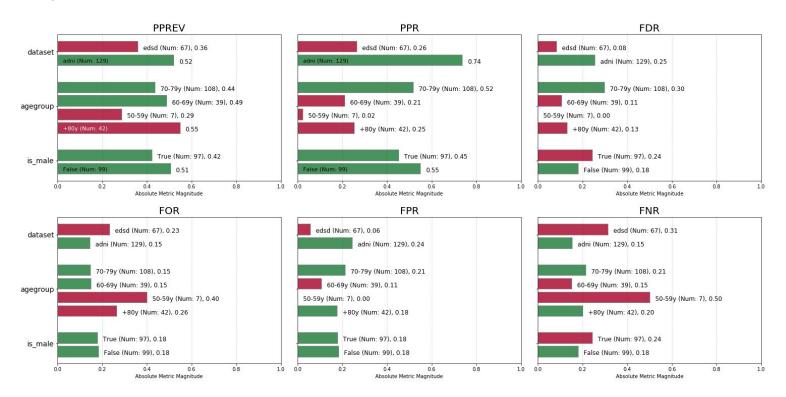




The same thing happened to us. We have no separate bank accounts or credit cards or assets of any kind. We both have the same high limits on our cards, including our AmEx Centurion card. But 10x on the Apple Card.



#### Aequitas toolkit



#### Robustezza modelli

Robustezza di un modello definita come la stabilità rispetto a piccole perturbazioni.

In determinati contesti modelli poco robusto possono avere conseguenze legate alla sicurezza.

Es: Modello in ambito computer vision che commette errori quando in presenza di artefatti legati alla compressione di un'immagine

#### Robustezza modelli

Robustezza di un modello definita come la **stabilità rispetto a piccole perturbazioni**.

In determinati contesti modelli poco robusto possono avere conseguenze legate alla sicurezza.

Es: Modello in ambito computer vision che commette errori quando in presenza di artefatti legati alla compressione di un'immagine

$$\|\mathbf{x} - \mathbf{x}'\| \le \delta$$



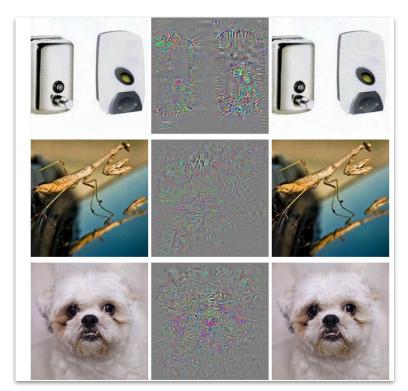
$$|f(\mathbf{x}) - f(\mathbf{x}')| \le \epsilon$$

#### **Adversarial robustness**

Fenomeno legato alla robustezza di un modello → Perturbazioni **mirate** che portano a errori importanti.

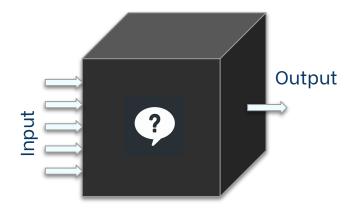


Source: Berkeley Al Research (BAIR)



"Intriguing properties of neural networks", Szegedy et.al, 2013

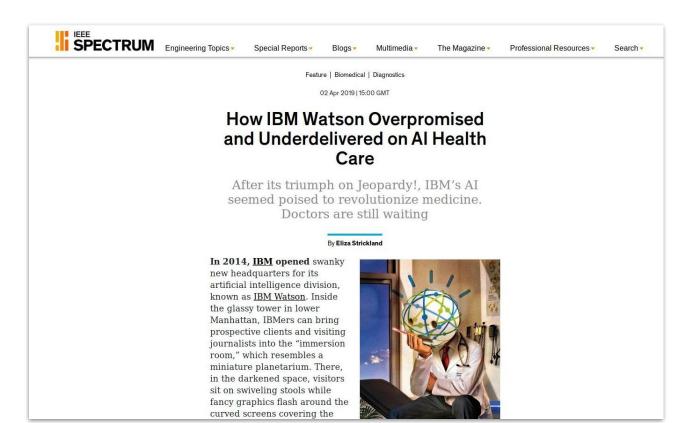
il problema della black-box



Fenomeni descritti fino ad ora aumentano con l'aumentare della **complessità** di un modello.

L'unica maniera per intercettarli in fase di debugging e' usando tecniche di **interpretazione** di modelli.

oltre al debugging



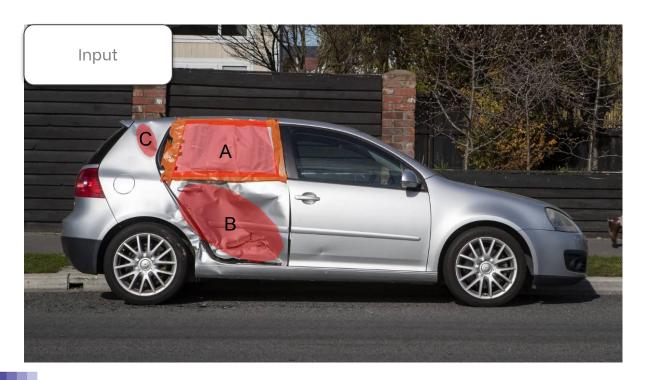
oltre al debugging



Output:

Damage= 2000€

oltre al debugging



Output:

Damage = 2000€

Breakdown:

A = 300€

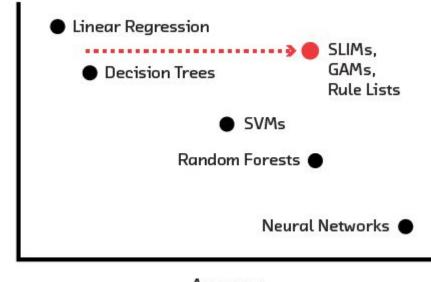
B = 1200€

C = 500€

Historical Example for B Label = 2500€



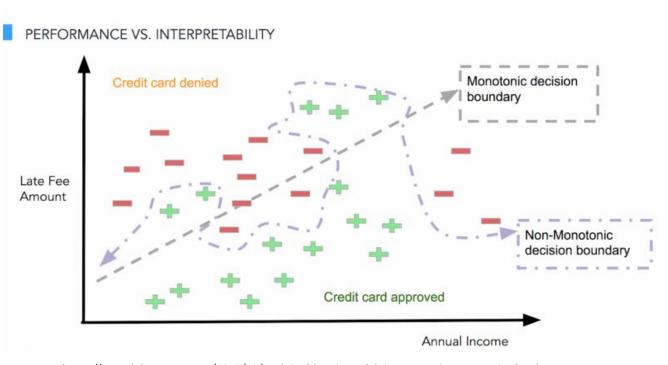
Interpretability



Accuracy

https://ff06-2020.fastforwardlabs.com/

#### Tassonomia eXplainable AI

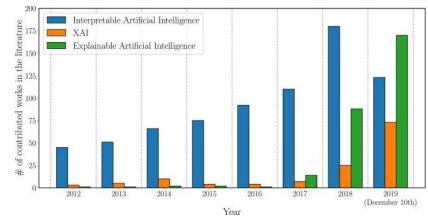


https://www.kdnuggets.com/2018/12/explainable-ai-model-interpretation-strategies.html

#### L'eXplainable AI (XAI)

Ambito di ricerca il cui scopo e' quello di aiutare umani a **interpretare** decisioni prese da modelli.

Interesse accademico e' in costante crescita → Sempre più metodi e librerie.

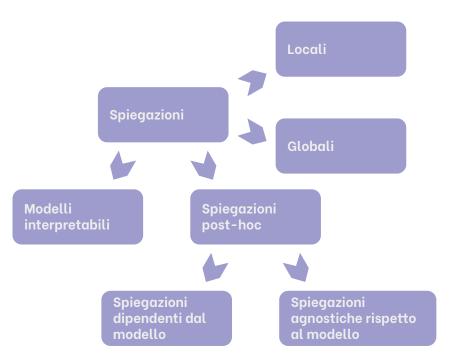


Arrieta et al, Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI, Information Fusion, 58, 2020

#### Tassonomia eXplainable AI

Modi di spiegare i modelli possono essere molteplici.

Nelle prossime slides ci focalizzeremo su spiegazioni **locali**, agnostiche e non.

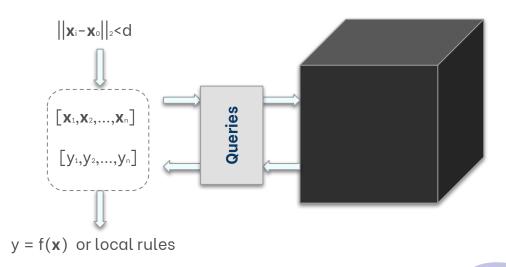


#### Metodi perturbativi

Agnostici rispetto al tipo di modello

Metodi disegnati per generare spiegazioni **locali** in maniera **agnostica**.

Spiegazioni generate ricostruendo un **modello semplificato** che approssimi il modello originale nelle vicinanze del punto da spiegare.

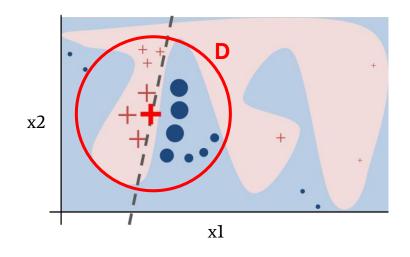


## Local Interpretable Model-agnostic Explanations (LIME)

Rientra tra i metodi più popolari, precursore approcci perturbativi.

#### Metodo:

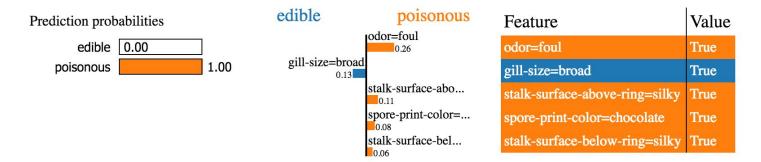
- Genera N punti in un intorno D del punto da spiegare.
- Ottieni la risposta del modello per questo insieme di punti.
- Costruisci un classificatore lineare usando le x,y ottenute nei passi precedenti.



https://arxiv.org/pdf/1602.04938.pdf

#### LIME

#### Esempio



- Spiegazioni generate usando diversi iperparametri (N punti, distanza D, etc)
- Può essere applicato a problemi su dati strutturati e non strutturati
- Spiegazioni possono non convergere.
- Spiegazioni non sono **prescrittive**.

#### Shapley values

Teoria dei giochi

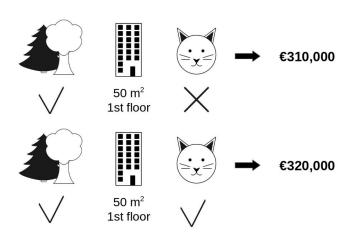
Concetto proveniente dalla teoria dei giochi: come ridistribuire la ricompensa di un gioco a cui ha partecipato un gruppo di giocatori in maniera cooperativa?

Coefficienti di Shapley definiscono una maniera per distribuire ricompensa tra partecipanti.

Applicato al machine learning:

Giocatori → Features

Ricompensa → Output del modello



https://christophm.github.io/interpretable-ml-book/

Coalitions 
$$\xrightarrow{h_x(z')}$$
 Feature values

Instance with "absent" features

https://christophm.github.io/interpretable-ml-book/

#### SHAP

Approssimazione Shapley Values

Metodo definisce una strategia per ottenere un'approssimazione dei valori di Shapley usando un approccio molto simile a LIME.

**KernelSHAP** → Metodo completamente agnostico rispetto al modello

**TreeSHAP** → Implementazione per modelli basati su alberi decisionali, molto più veloce

#### **SHAP**

#### Approssimazione Shapley Values



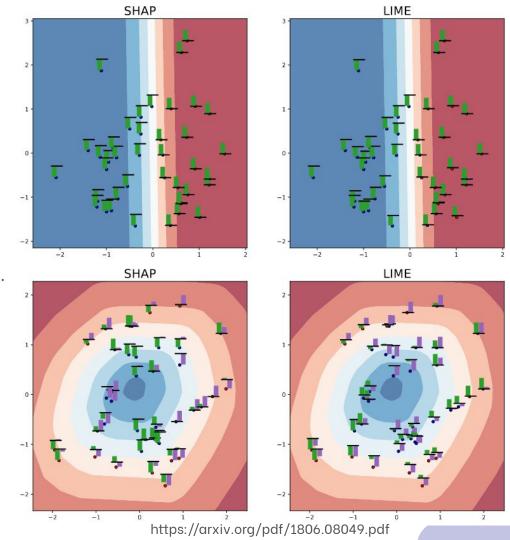
- Libreria SHAP offre oltre al metodo stesso librerie di visualizzazione molto curate
- KernelSHAP e' decisamente lento.
- Così come per LIME la generazione di punti sintetici non tiene conto delle dipendenze statistiche tra features.

#### Robustezza spiegazioni

Per alcuni tipi di problemi, librerie perturbative possono essere affette da problemi di robustezza

→ Piccolo cambiamento input può cambiare completamente spiegazione.

Importante monitorare qualità spiegazioni.



#### **Esercizio SHAP**

https://github.com/Clearbox-AI/Corso\_MLOps/blob/main/sessione3/SHAP\_examples.ipynb

Saper indicare quali dati di allenamento hanno influito su una particolare predizione.

Saper indicare quali dati di allenamento hanno influito su una particolare predizione.

ID immobile	locali	tipo	Superficie (m2)	bagni	giardino	Venduto a
n	3	villa	150	2	si	315000 €

Saper indicare quali dati di allenamento hanno influito su una particolare predizione.

ID immobile	locali	tipo	Superficie (m2)	bagni	giardino	Venduto a
n	3	villa	150	2	si	315000 €

#### Questo immobile proveniente dai dati di allenamento e' molto simile:

ID immobile	locali	tipo	Superficie (m2)	bagni	giardino	Venduto a
424	3	villa	140	2	si	310000€

Saper indicare quali dati di allenamento hanno influito su una particolare predizione.

Problema: come definire similitudini tra punti?

Approccio più immediato → Nearest Neighbours utilizzando input stessi o rappresentazioni intermedie interne ai modelli (es: attivazioni in reti neurali)



https://beenkim.github.io/papers/KIM2016NIPS\_MMD.pdf

#### Esempi controfattuali

ragionamento tramite scenari ipotetici

Esempi che **cambiano la predizione** in una determinata direzione stando all'interno di **vincoli** specifici.

Es: Se avessi avuto 5 anni in più il prestito sarebbe stato accettato.

Impostati come problema di ottimizzazione vincolata nello spazio delle features.

$$\|\mathbf{x} - \mathbf{x}'\| \le \delta$$

$$|f(\mathbf{x}) - f(\mathbf{x}')| > \epsilon$$

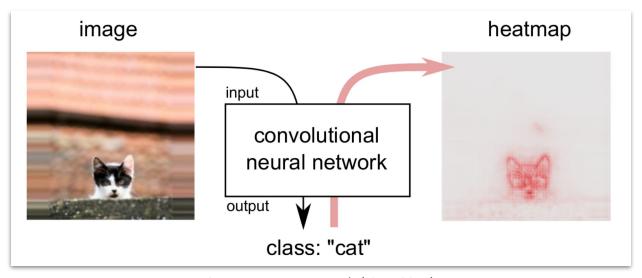
## **Metodi intrusivi**

Aprire la black-box

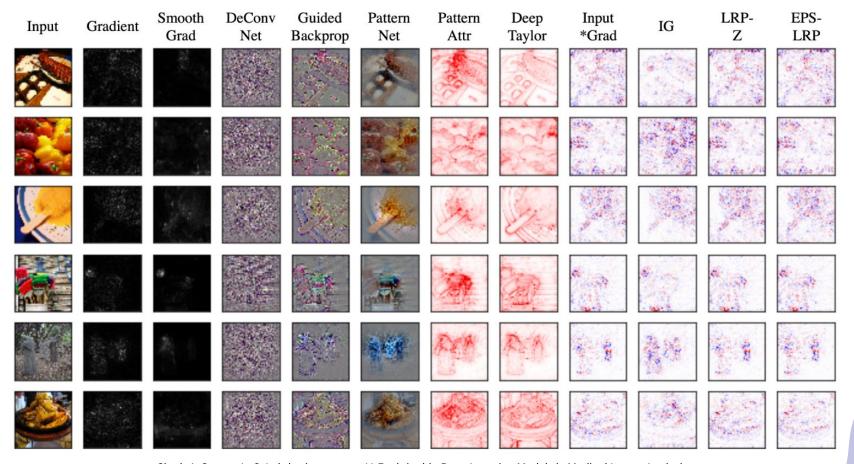
#### **Metodi intrusivi**

Aprire la black-box

Esempio: Deep Taylor Decomposition



Source: Montavon et al. (ICML 2016)



Singh A, Sengupta S, Lakshminarayanan V. Explainable Deep Learning Models in Medical Image Analysis. *Journal of Imaging*. 2020; 6(6):52. https://doi.org/10.3390/jimaging6060052

# Librerie interpretazione reti neurali

**CAPTUM** (<a href="https://github.com/pytorch/captum">https://github.com/pytorch/captum</a>). Librerie interpretabilità per modelli scritti in PyTorch.

**iNNvestigate** (<a href="https://github.com/albermax/innvestigate">https://github.com/albermax/innvestigate</a>). Stesso ma per modelli scritti in Keras-Tensorflow (solamente 1.0, 2.0 in fase di sviluppo)

## Clustering spiegazioni

Passare da analisi locale spiegazioni ad analisi globale. Come?

Raggruppando le spiegazioni in maniera non supervisionata e analizzando i clusters trovati come **comportamenti** del modello.

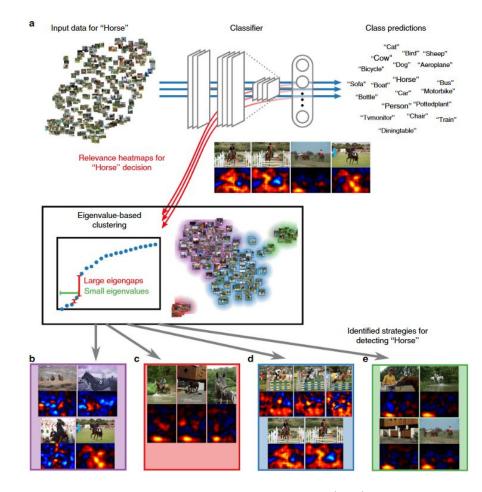
Idealmente approccio permette di isolare comportamenti non desiderati.

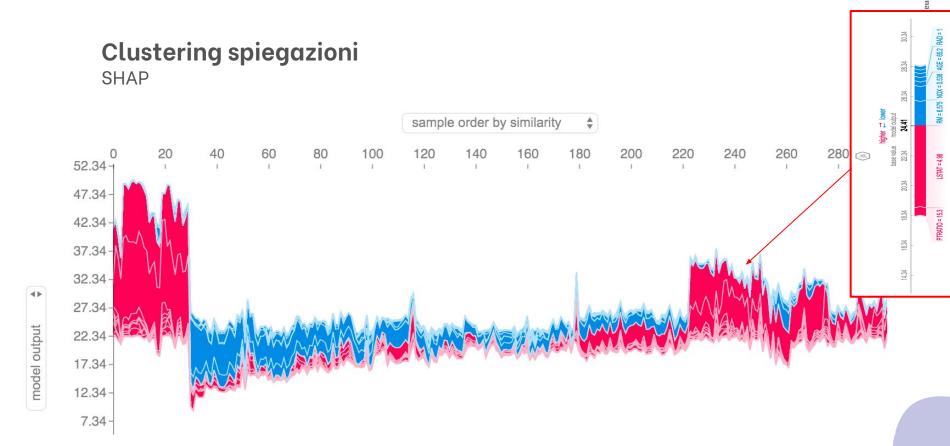
### Clustering spiegazioni

Passare da analisi locale spiegazioni ad analisi globale. Come?

Raggruppando le spiegazioni in maniera non supervisionata e analizzando i clusters trovati come **comportamenti** del modello.

Idealmente approccio permette di isolare comportamenti non desiderati.





# **Esercizio clustering con SHAP**

https://github.com/Clearbox-AI/Corso\_MLOps/blob/main/sessione3/SHAP\_examples.ipynb

# Analisi degli errori: motivazione

Un modello validato ed interpretabile sarà comunque soggetto ad errori.

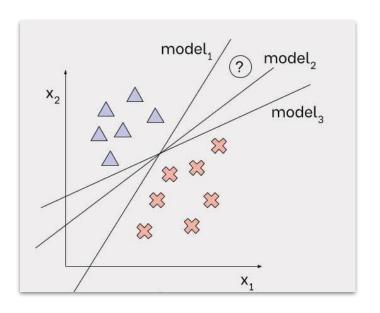
Dobbiamo essere in grado di stimare la **probabilità di incorrere** in errore e di permettere a modelli di optare di non dare una risposta.

## Incertezza epistemica

o riducibile

Incertezza epistemica rappresenta l'incertezza dovuta ad una **conoscenza incompleta** del problema analizzato.

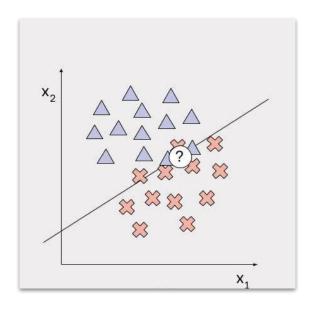
In ambito machine learning e' solitamente associata a mancanza di informazione a livello di dati.



#### Incertezza aleatoria

o irriducibile

Questo tipo di incertezza e' associata ad una presenza di **rumore** a livello di dati che non può essere ridotto tramite feature engineering o raccolta dati.



#### Calibrazione modelli

Definizione

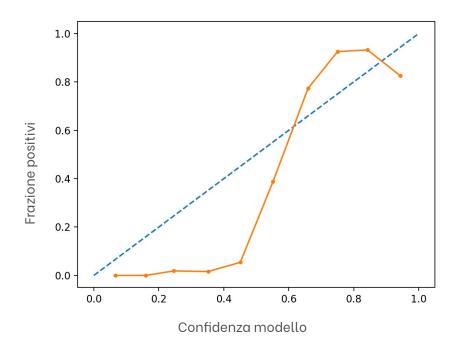
Approccio comune in ambito machine learning: incorporare le varie sorgenti di incertezza all'interno di un'unica quantità, la **confidenza del modello**.

Problema sorge quando in presenza di modelli cosiddetti non calibrati:

es. una confidenza del 90% in un'etichetta deve corrispondere dal vivo in un rateo di successo analogo.

#### Calibrazione modelli Metodi

Calibrazione di un modello può essere quantificata tramite la curva di calibrazione (o reliability diagram)



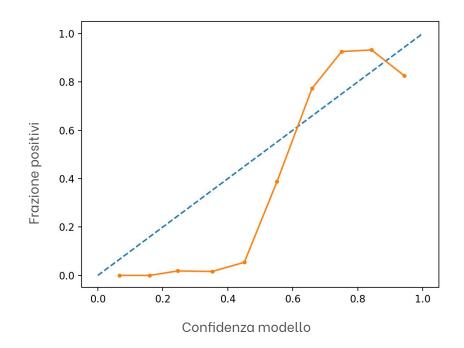
#### Calibrazione modelli Metodi

Calibrazione di un modello può essere quantificata tramite la curva

Metodi per migliorare calibrazione di un modello non calibrato:

di calibrazione (o reliability

diagram)

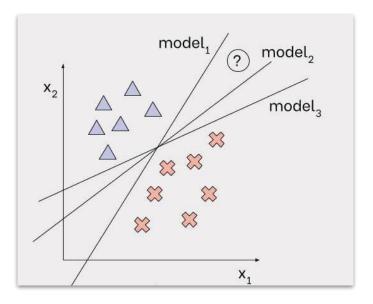


- Platt scaling: fit di una funzione di tipo sigmoide da aggiungere all'output del modello
- Isotonic regression: utilizzo di una funzione di regressione isotonica

#### Calibrazione modelli

Esercizio

https://github.com/Clearbox-AI/Corso\_MLOps/blob/main/sessione3/Calibrazione\_Anomaly\_Detection.ipynb



### **Anomaly detection**

Definizione limiti operativi modello

Prima di spostarsi nella fase di produzione bisogna definire un **range operativo** per un dato modello.

Modelli sono allenati su determinate distribuzioni di dati, devo assicurarmi che i dati in produzione provengano da distribuzioni simili, altrimenti il modello starebbe lavorando in un range sconosciuto.

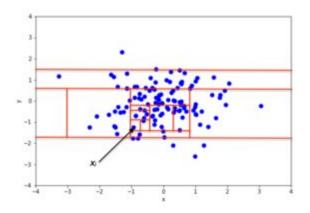
Come automatizzare questo processo di **rejection** di eventuali punti mai visti? Tramite **anomaly detection**.

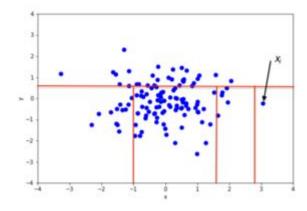
#### **Isolation Forests**

Trovare anomalies tramite alberi decisionali

Idea: quando creiamo un albero decisionale i punti più anomali sono i più facili da isolare tramite splitting. (Foglie contenenti anomalie tendono ad essere vicine alla radice dell'albero)

Un Isolation forest consiste in un numero di isolation trees dove i punti anomali sono quelli isolati usando il percorso più breve.





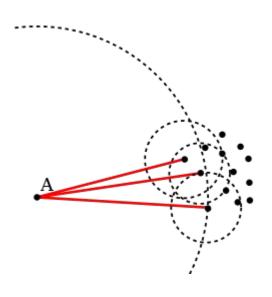
#### **Local Outlier Factor**

Analisi densità locali

Idea: Comparare la densità locale di un punto con densità locale di punti vicini.

Così come isolation forest e' basata su alberti decisionale, LOF e' basato su tecniche di tipo **Nearest Neighbours**.

Caratterizzato da stesse limitazioni associate a kNN: quale **metrica** usare per calcolare distanze tra punti?



## **Anomaly detection**

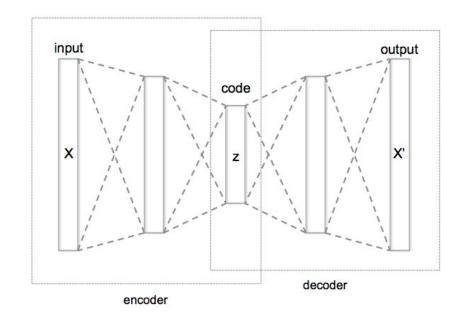
Esercizio con scikit-learn

https://github.com/Clearbox-AI/Corso\_MLOps/blob/main/sessione3/Calibrazione\_Anomaly\_Detection.ipynb

#### **AutoEncoders**

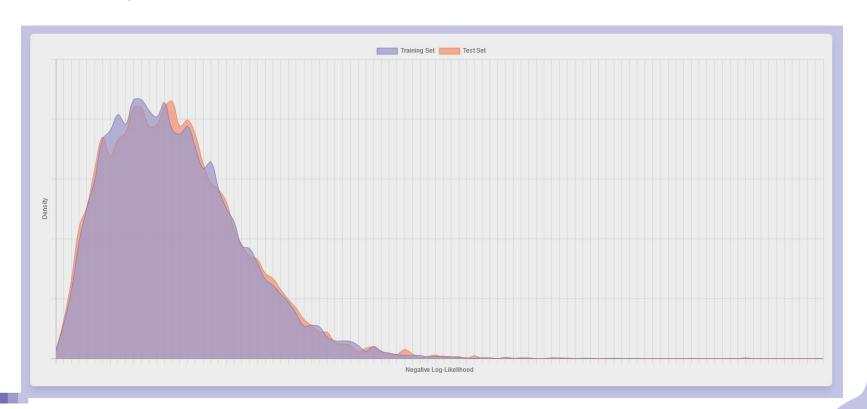
Idea: allenare un modello (basato su reti neurali) a **comprimere** e **ricostruire** i dati di allenamento del problema in esame.

Performando questo task su dati non visti prima l'errore di ricostruzione tenderà ad essere più' alto per punti che non appartengono alla distribuzione di allenamento.



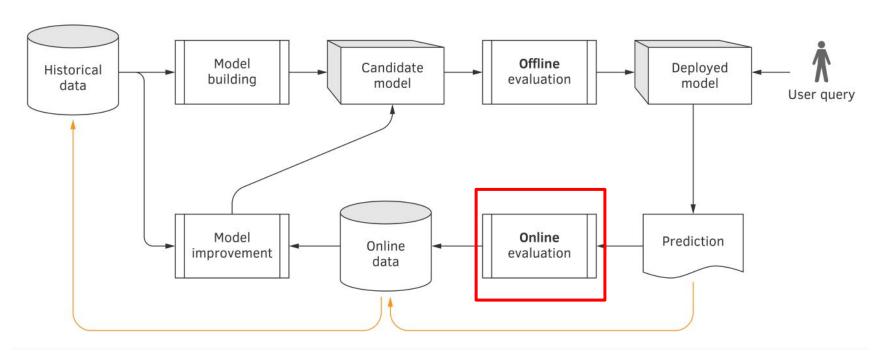
### **AutoEncoders**

Esempio errore ricostruzione



## Monitoraggio e miglioramento continuo

Prossima lezione





## **Thanks for Reading**

Feel free to contact us:



www.clearbox.ai



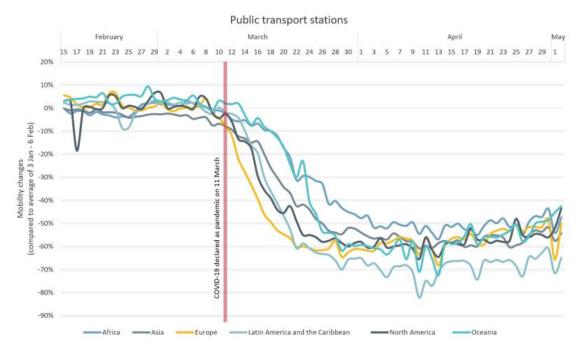
shalini@clearbox.ai giovannetti@clearbox.ai



@ClearboxAI

## Monitoraggio

#### Data-drift



## **Concept-drift**